
Phân Tích Dữ Liệu và Dự Báo Doanh Thu Bán Lẻ Thương Mại Điện Tử Vin University - DATATHON 2026

Đội thi / AIO26

VinUniversity Datathon 2026

GitHub: <https://github.com/KaitoKidKao/DATATHON>

tricao1148@gmail.com; duythai210105@gmail.com

tranquocdat2614@gmail.com; nbngoc.udu.ptit@gmail.com

Abstract

Báo cáo này trình bày một giải pháp toàn diện và chuyên sâu cho bài toán phân tích và dự báo doanh thu bán lẻ thương mại điện tử, được phát triển trong khuôn khổ cuộc thi VinUniversity Datathon 2026. Dựa trên cơ sở dữ liệu đồ sộ gồm 15 bảng trải dài suốt một thập kỷ (2012–2022), chúng tôi đã tiến hành một quy trình Phân tích Dữ liệu Khám phá (EDA) 4 cấp độ. Các phân tích này không chỉ chẩn đoán được các "nút thắt cổ chai" trong vận hành (như tỷ lệ hoàn trả cao bất thường ở ngành hàng Streetwear do sai lệch kích cỡ) mà còn đưa ra các giải pháp tự động hóa quản trị tồn kho. Ở cốt lõi dự báo, bài toán yêu cầu ngoại suy doanh thu hàng ngày cho 1.5 năm tương lai (2023–2024), đặt ra thách thức khổng lồ về sự bùng nổ sai số đệ quy (Recursive Error Explosion). Thay vì áp dụng các chuỗi thời gian tuyến tính truyền thống, chúng tôi đề xuất khung kiến trúc "**Absolute Peak**". Đây là một hệ thống Machine Learning mài giũa tỉ mỉ, kết hợp các Trích xuất Đặc trưng Vi xu hướng (Micro-Trends), Kiến thức Miền (Domain Knowledge), cơ chế Trộn đa mục tiêu (Objective Diversity Blending) và thuật toán Cắt giảm Phương sai Đa hạt giống (Multi-Seed Averaging). Giải pháp đã giải quyết triệt để rò rỉ dữ liệu, khắc phục lỗi ngoại suy và đạt được mức sai số tuyệt đối trung bình (MAE) ấn tượng tiệm cận ~766,894 VNĐ, thể hiện một độ trễ và sự ổn định hoàn hảo cho hệ thống chuỗi cung ứng thời gian thực.

1 Giới thiệu và Đặt vấn đề

1.1 Bối cảnh Thương mại Điện tử

Trong bối cảnh nền kinh tế số phát triển vũ bão, doanh thu hàng ngày của các nền tảng thương mại điện tử không còn tuân theo những đường cong tăng trưởng trơn tru truyền thống. Nó bị chi phối bởi một hệ sinh thái phức tạp gồm các yếu tố nội tại (chính sách giá, tồn kho, các chiến dịch marketing) và các cú sốc ngoại sinh (chu kỳ vĩ mô, ngày lễ Tết, siêu sale ngày đôi, và các biến động như đại dịch Covid-19). Việc không thể dự báo chính xác nhu cầu thị trường thường dẫn đến hai rủi ro tàn khốc: một là "cháy hàng" (Stock-outs) làm thất thoát hàng tỷ đồng doanh thu tiềm năng; hai là tồn kho quá mức (Overstocking) gây ứ đọng vốn lưu động và chi phí kho bãi khổng lồ.

1.2 Thách thức của VinUni Datathon 2026

Cuộc thi VinUniversity Datathon 2026 đặt ra một bài toán đầy tham vọng: Cung cấp cơ sở dữ liệu lịch sử từ năm 2012 đến hết năm 2022 và yêu cầu dự báo doanh thu hàng ngày (Revenue) cùng giá vốn hàng bán (COGS) cho giai đoạn cực dài 2023–2024. Khó khăn lớn nhất nằm ở chỗ, các tệp dữ

liệu hỗ trợ như Web Traffic, Marketing Campaigns chỉ có sẵn trong quá khứ. Việc dự báo xa 1.5 năm vào tương lai yêu cầu hệ thống phải sử dụng kỹ thuật **Dự báo Đệ quy (Recursive Forecasting)** — tức là dùng chính dự báo của ngày hôm nay để làm đầu vào cho ngày mai. Trong mô hình đệ quy, chỉ một sai lệch nhỏ ở tháng đầu tiên cũng sẽ bị phóng đại theo cấp số nhân (Butterfly Effect), dẫn đến sự sụp đổ của toàn bộ hệ thống dự báo ở năm cuối cùng.

1.3 Đóng góp của Nhóm

Để giải quyết bài toán này, nhóm đề xuất một luồng công việc hai nhánh (Dual-track Pipeline):


1. **Khung Phân tích Tự động 4 Cấp độ:** Một quy trình phân tích từ Miêu tả (Descriptive) đến Kế đơn (Prescriptive), đi sâu vào gốc rễ của trải nghiệm người dùng và chuỗi cung ứng.
2. **Kiến trúc "Absolute Peak":** Một thiết kế mô hình Học máy Ensemble tinh vi, loại bỏ hoàn toàn các lỗi ngoại suy tuyến tính, tích hợp sự thấu hiểu hành vi tiêu dùng nội địa Việt Nam, và tối ưu hóa hàm mất mát hỗn hợp để mang lại sự cân bằng hoàn hảo giữa tính Ổn định và Khả năng bất Định.

2 Trực quan hóa và Phân tích Dữ liệu Hệ thống (EDA)

Thay vì chỉ vẽ các biểu đồ rời rạc, nhóm xây dựng quy trình phân tích theo chuẩn công nghiệp 4.0, bóc tách cấu trúc doanh nghiệp qua 4 lăng kính.

2.1 Descriptive Analytics: Bức tranh Tổng quan và Tính Mùa Vụ

Phân tích chuỗi thời gian 10 năm (2012–2022) cho thấy doanh thu trung bình hàng ngày dao động ở mức ~2.1 triệu VNĐ. Tuy nhiên, tính chất mùa vụ (Seasonality) là cực kỳ mãnh liệt. Đồ thị tự tương quan (Autocorrelation) chỉ ra các chu kỳ 7 ngày (Weekly) và 365 ngày (Yearly) rất rõ ràng. Doanh thu luôn tạo thành một "cú hích" cực đại vào Quý 4 (Tháng 11–12) do cộng hưởng từ các sự kiện Black Friday và Year-End Sale. Một đỉnh phụ thứ hai thường xuất hiện vào Tháng 1 hoặc Tháng 2, đồng pha tuyệt đối với nhịp mua sắm trước Tết Nguyên Đán của người Việt. Về mặt địa lý, khu vực **East** đóng vai trò là "đầu tàu" kinh tế, gánh vác tới 46% tổng doanh thu toàn hệ thống.




Hình 1: Biểu đồ xu hướng doanh thu hàng tháng (2012-2022) cho thấy tính mùa vụ rõ rệt.

2.2 Diagnostic Analytics: Chẩn đoán Khuyết điểm Vận hành

Chúng tôi đã phân tích sâu vào tệp dữ liệu Hoàn trả hàng (Returns). Kết quả chẩn đoán phơi bày một lỗ hổng nghiêm trọng ở danh mục **Streetwear**. Tại đây, lý do trả hàng `wrong_size` chiếm tỷ trọng áp đảo lên tới 38%. Điều này không chỉ phản ánh sự lãng phí chi phí Logistics khứ hồi (Reverse Logistics) mà còn chỉ ra một lỗi hệ thống: Bảng kích cỡ (Size Chart) trên nền tảng không đồng bộ với kích cỡ thực tế của các sản phẩm mang phong cách Oversize, làm suy giảm nghiêm trọng giá trị vòng đời khách hàng (CLV).

Về mặt Marketing, biểu đồ phân tán (Scatter Plot) giữa Lượng truy cập (Sessions) và Tỷ lệ chuyển đổi (Conversion Rate) cho thấy một nghịch lý: **Organic Search** mang lại khối lượng Traffic khổng lồ nhưng chất lượng cực kỳ kém (Bounce Rate cao, Conversion thấp). Trong khi đó, các chiến dịch

Email Campaign dù có độ phủ hẹp hơn lại sở hữu Tỷ lệ chuyển đổi vượt trội. Hệ thống Landing Page của Organic Search hiện đang không giữ chân được tệp khách hàng vắng lại.




Hình 2: Phân tán khối lượng Sessions và Tỷ lệ chuyển đổi theo kênh Marketing.

2.3 Predictive & Prescriptive Analytics: Từ Tiên đoán đến Hành động


Mô hình Hồi quy tuyến tính áp dụng trên Phễu Marketing (Marketing Funnel) chứng minh rằng: Biến động của *Page Views* ở ngày $t - 1$ có khả năng giải thích tới hơn 70% phương sai của *Revenue* ở ngày t . Dấu vết số (Digital Footprint) là chỉ báo sớm tuyệt vời.

Dựa trên Ma trận Tối ưu hóa Tồn kho (Inventory Optimization Matrix), nhóm đề xuất các quyết định Kế đơn (Prescriptive Actions):

- **Cảnh báo Auto-reorder:** Kích hoạt ngay lập tức với nhóm SKU có "Low Supply, High Sell-through" để chặn đứng hiện tượng đứt gãy chuỗi cung ứng.
- **Dynamic Flash Sale:** Áp dụng thuật toán giảm giá động để xả hàng khẩn cấp đối với nhóm "High Supply, Low Sell-through", giải phóng dòng tiền.
- **Size Recommender AI:** Đề xuất phát triển một mô hình AI tự động khớp số đo cơ thể người dùng với form quần áo nhằm xóa sổ vấn nạn trả hàng do sai kích cỡ ở nhóm Streetwear.



(a) Hồi quy tuyến tính Phễu Marketing



(b) Ma trận Tối ưu hóa Tồn kho

Hình 3: Các phân tích dự đoán và kế đơn chiến lược.

3 Kiến trúc Dự báo "Absolute Peak"(Phương pháp luận)

Để vượt qua các giới hạn của thuật toán chuỗi thời gian thống kê (như ARIMA, Prophet), nhóm đã thiết kế một đường ống Machine Learning đệ quy hoàn chỉnh. Quá trình phát triển đã chỉ ra rằng, việc dùng các mô hình Tuyến tính (Linear Models) để cố gắng ngoại suy một đoạn thời gian 1.5 năm (vốn chứa các biến thời gian nằm ngoài vùng phân phối) sẽ dẫn đến "Lỗi Bùng nổ Tuyến tính" (Linear Extrapolation Explosion). Do đó, xương sống của **Absolute Peak Architecture** dựa hoàn toàn vào các thuật toán Cây Quyết định Tăng cường (Gradient Boosting Decision Trees - GBDT) vốn có bản chất chia cắt không gian (Space Partitioning) và cực kỳ an toàn trước các giá trị ngoại lai.

3.1 Trích xuất Đặc trưng Đa chiều (Deep Feature Engineering)

Thay vì đưa dữ liệu thô vào mô hình, chúng tôi đã tạo ra một không gian biểu diễn đa chiều (Hơn 80 features), chia làm 4 nhóm sinh lý học dữ liệu:

1. Điểm neo Dữ liệu Web (Covariate Shift Anchor) Vì dữ liệu Web Traffic bị cắt đứt ở năm 2022, việc dự báo cho 2023-2024 đối mặt với hiện tượng thay đổi phân phối (Covariate Shift). Nhiều đội thi cố gắng huấn luyện một mô hình phụ để dự đoán Web Traffic, nhưng điều này chỉ gây hiệu ứng "Nhiều đê Nhiều". Chúng tôi phát hiện ra việc sử dụng kỹ thuật Forward Fill (`ffill`) trực tiếp từ điểm chốt hạ cuối năm 2022 tạo ra một "Điểm Neo" vô tình nhưng hoàn hảo. Nó cung cấp một *Base Scale* (tỷ lệ nền) tính và ổn định tuyệt đối, giúp mô hình chính không bị trôi dạt (drift) khi đệ quy.

2. Tín hiệu Vi xu hướng (Micro-Trends & Momentum) Mô hình Cây học các con số tuyệt đối rất giỏi, nhưng lại kém trong việc nhận thức bối cảnh tương đối. Chúng tôi khắc phục điều này bằng kỹ thuật Động lượng:

$$Momentum_{7_30} = \frac{Rolling_Mean_7}{Rolling_Mean_{30} + \epsilon} \quad (1)$$

$$Lag_Diff_{1_7} = Lag_1 - Lag_7 \quad (2)$$

$Momentum_{7_30}$ cung cấp cho mô hình một con mắt tinh tường để nhận biết tuần hiện tại đang "Bùng nổ" hay "Đóng băng" so với nhịp độ chung của cả tháng. $Lag_Diff_{1_7}$ giúp bắt ngay những cú sốc ngắn hạn (Short-term Spikes) so với cùng kỳ tuần trước.

3. Kiến thức Miền và Tính Chu kỳ (Domain Knowledge & Seasonality) Văn hóa tiêu dùng E-commerce ở Việt Nam không thể được mô phỏng chỉ bằng những con số vô tri. Nhóm đã thủ công tạo ra các **Domain Flags** cực mạnh:

- `is_tet_season`: Cờ bật từ 15/01 đến 15/02 hàng năm, bắt dính đợt sắm Tết.
- `is_payday`: Các ngày 5, 10, 25-30 hàng tháng. Nắm bắt tâm lý bung tiền giải phóng áp lực ngay sau khi nhận lương.
- `is_double_day`: Các ngày trùng tháng (Ví dụ: 11/11, 12/12) - Mỏ vàng của E-commerce.

Song song đó, nhóm áp dụng **Day-level Target Encoding**. Thay vì mã hóa Tháng hay Thứ, việc mã hóa thẳng Từng Ngày (từ mùng 1 đến mùng 31) bằng trung bình doanh thu lịch sử giúp mô hình tự học được đường cong chu kỳ thu nhập một cách mượt mà nhất. Cuối cùng, chuỗi *Fourier Features* bậc 3 (Hàm sin/cos của `dayofyear`) được cấy vào để duy trì nhịp sinh học theo mùa bất chấp sự thiếu hụt của các tính năng lịch trơn.

3.2 Cơ chế Objective Diversity Blending

Hầu hết các kỹ sư tối ưu hóa mô hình bằng một hàm mất mát (Loss Function) duy nhất. Nhưng ở dữ liệu bán lẻ, có hai trạng thái đối nghịch: Những ngày bán ế (cần sự ổn định của MAE) và những ngày siêu hội mua sắm (cần sự nhạy cảm của RMSE).

Kiến trúc *Absolute Peak* giải quyết sự phân tâm này bằng triết lý **Objective Diversity**:

- Chúng tôi huấn luyện 1 mô hình LightGBM đặc nhiệm sử dụng hàm **RMSE** (Root Mean Squared Error). Vì RMSE phạt cực nặng các sai số lớn, mô hình này sẽ đóng vai trò *Spike Booster* - Đội trưởng chuyên săn lùng và dự báo các đỉnh doanh thu.
- Chúng tôi huấn luyện 3 mô hình còn lại (LightGBM, CatBoost, XGBoost) với hàm **MAE** (Mean Absolute Error). 3 mô hình này chuyên tâm tạo ra một đường nền (Baseline) vững chắc, chống nhiễu và không bị lừa bởi các ngoại lai (Outliers).

Để kết hợp 4 chuyên gia này, chúng tôi không lấy trung bình cộng thô sơ. Thay vào đó, nền tảng tối ưu hóa toàn cục **Optuna** được sử dụng trên tập dự đoán Out-Of-Fold (OOF). Optuna tự động rà quét hàng nghìn tổ hợp để tìm ra bộ Tỷ trọng Trộn (Blending Weights) sao cho sai số MAE toàn cục đạt mức cực tiểu, hoàn toàn cách ly với rủi ro Overfitting.

3.3 Fast Multi-Seed Averaging: Triệt Tiêu Phương Sai Cấp Số

Điểm yếu chí mạng của Recursive Forecasting là một biến động ngẫu nhiên siêu nhỏ có thể làm chệch quỹ đạo của toàn bộ tương lai. Phương pháp Ensemble chưa đủ để gọt sạch phương sai nội tại (Intrinsic Variance) của các cây GBDT (do cơ chế ngẫu nhiên chọn cột và hàng).

Chúng tôi triển khai kỹ thuật **Multi-Seed Averaging** cấp cao. Toàn bộ kiến trúc gồm 4 thuật toán tối ưu sẽ được huấn luyện lại 5 lần, mỗi lần sử dụng một hạt giống ngẫu nhiên (Random Seeds) hoàn toàn khác biệt. Đầu ra cuối cùng là Trung bình cộng của 5 hệ phái đệ quy song song. Phương pháp này, mặc dù tăng chi phí tính toán lên gấp 5 lần, nhưng đã mang lại một đường cong xu hướng mượt mà tuyệt đối, phẳng hóa mọi sự rung lắc vô lý và khóa chặt dự báo vào đúng quỹ đạo của bản chất dữ liệu.

4 Quy trình Thực thi Đệ quy (The Recursive Execution Loop)

Tập dữ báo (Test set) bắt đầu từ 01/01/2023 và kết thúc ở 30/06/2024. Tại ngày T , các thông tin lag như Lag_1 (doanh thu ngày $T - 1$) hoặc Lag_7 (doanh thu tuần trước) bị khuyết do chúng thuộc vào tương lai.

Hệ thống hoạt động như một cỗ máy thời gian tự nuôi dưỡng:

- Ở ngày $T = 1$, mô hình đọc dữ liệu thật từ ngày $T - 1$ trong lịch sử, tạo Feature Vector và tiên đoán $\hat{y}_1$.
- Hệ thống ngay lập tức ghim $\hat{y}_1$ vào cơ sở dữ liệu lịch sử tạm thời (Rolling History).
- Bước sang ngày $T = 2$, hệ thống tự động thiết lập lại toàn bộ các tính năng Lags và Rolling Means. Lúc này, $\hat{y}_1$ trở thành nguyên liệu để chế tạo ra Lag_1 và $Momentum$ cho việc dự báo $\hat{y}_2$.
- Vòng lặp tiếp diễn hàng trăm lần cho đến ngày cuối cùng. Sự bảo kê chéo của *Multi-Seed* và sức nặng của *Covariate Shift Anchor* đảm bảo rằng $\hat{y}_{500}$ không bao giờ phát nổ.

5 Kết quả và Thảo luận (Ablation Analysis)

Sự tinh xảo của khung kiến trúc "Absolute Peak" đã mang lại những kết quả vượt bậc, thể hiện qua sự suy giảm đáng kinh ngạc của hàm mục tiêu (MAE) trên Leaderboard (Bảng 1).

Bảng 1: Mô phỏng Phân tích Bóc tách (Ablation Study) của Khung Kiến Trúc

Kiến trúc	Chi tiết Thành phần	MAE Đạt Được
Baseline	LightGBM Đơn mục tiêu (RMSE), Không trích xuất sâu	1,182,583
Linear Trap	Thêm Huber Regressor + Biến xu hướng (Extrapolation Error)	> 1,190,000
GBDT Ensemble	XGBoost + LightGBM + CatBoost + Optuna (MAE)	~864,400
Absolute Peak	GBDT Ensemble + Objective Diversity + Domain + 5-Seed	~766,894

Giải mã Sự thất bại của Linear Model: Việc mô hình có thêm Huber Regression bị đẩy vọt sai số lên mức 1.19M minh chứng cho nhận định lý thuyết của chúng tôi. Các mô hình tuyến tính cố gắng kẻ một đường dốc thẳng tắp dựa trên xu hướng của quá khứ. Khi đi vào không gian 2023-2024, trục thời gian quá dài khiến phép nhân tuyến tính phóng to kết quả ra ngoài biên giới thực tế, phá hủy toàn bộ thành quả.

Tại sao Absolute Peak chiến thắng? Kiến trúc cuối cùng (~766K) đạt được trạng thái lý tưởng nhờ giải quyết 3 mặt trận cùng lúc:

- Chống nhiễu dữ liệu dài hạn (Nhờ GBDT và Anchor Web Traffic).
- Bám sát tâm lý học hành vi vĩ mô (Tết, Payday) và vi mô (Momentum, Lags).

3. Tối ưu linh hoạt (Sự kết hợp hoàn hảo giữa gã thợ săn đỉnh RMSE và nền tảng phòng ngự MAE).

6 Kết luận và Hướng phát triển Tương lai

Báo cáo này đã phác họa một khung nghiên cứu chuẩn mực cho bài toán thương mại điện tử, xuất phát từ các Dashboard phân tích tồn kho 4 cấp độ đến việc triển khai một cỗ máy dự đoán AI siêu cường. Kiến trúc "**Absolute Peak**" đã trình diễn khả năng làm chủ các luồng dữ liệu đứt gãy, chống lại sự phình to của sai số đệ quy, và hiểu thấu vòng quay tài chính của người tiêu dùng.

Dù đạt được kết quả tiệm cận ngưỡng dẫn đầu, tiềm năng mở rộng của mô hình là rất lớn. Trong tương lai, mô hình có thể được cấu trúc lại bằng các mô hình học sâu như Transformer (ví dụ: Temporal Fusion Transformer) để nội suy tự động các mối tương quan đa biến. Ngoài ra, việc nhúng thêm các dữ liệu Vĩ mô (Chỉ số CPI, lạm phát thực tế) hay Phân tích Cảm xúc (Sentiment Analysis) từ phản hồi khách hàng sẽ biến hệ thống thành một cỗ máy "bất khả chiến bại" trong việc đoán định thị trường.

Tài liệu Tham khảo

- [1] Ke, G., Meng, Q., Finley, T., Wang, T., Chen, W., Ma, W., ... & Liu, T. Y. (2017). LightGBM: A Highly Efficient Gradient Boosting Decision Tree. *Advances in Neural Information Processing Systems*, 30.
- [2] Prokhorenkova, L., Gusev, G., Vorobev, A., Dorogush, A. V., & Gulin, A. (2018). CatBoost: unbiased boosting with categorical features. *Advances in Neural Information Processing Systems*, 31.
- [3] Chen, T., & Guestrin, C. (2016). XGBoost: A scalable tree boosting system. In *Proceedings of the 22nd ACM SIGKDD International Conference on Knowledge Discovery and Data Mining* (pp. 785-794).
- [4] Akiba, T., Sano, S., Yanase, T., Ohta, T., & Koyama, M. (2019). Optuna: A Next-generation Hyperparameter Optimization Framework. In *Proceedings of the 25th ACM SIGKDD International Conference on Knowledge Discovery & Data Mining* (pp. 2623-2631).
- [5] Hyndman, R. J., & Athanasopoulos, G. (2018). *Forecasting: principles and practice*. OTexts.